

PRODUCTSTAR

АНАЛИТИЧЕСКИЙ ПРОЕКТ НА PYTHON



Содержание урока

- ✦ Разведочный анализ данных
- ✦ Описательный анализ данных
- ✦ Визуализация данных
- ✦ Корреляционный анализ
- ✦ Воркшоп



Lead Data Scientist, «Альмира»

Преподаватель курсов по Data Science

Data Scientist, Freelance

КИРИЛЛ ЕРОХИН

- ✦ Запустил два проекта с нуля по специфике NLP и LLM
- ✦ Администрирую сервер с 4xGPU для обучения моделей
- ✦ Преисполнился в сборе данных с нуля



РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ



Разведочный анализ данных (EDA/Exploratory Data Analysis)
или исследовательский анализ данных — это подход
к анализу данных для обобщения их основных характеристик,
визуализации, поиска выбросов и аномалий, и понимания
взаимосвязи данных. Процесс, который позволяет лучше
понять природу данных

Для чего нужен анализ данных

- Позволяет получить более глубокое понимание данных
- Помогает выявить скрытые закономерности и отношения
- Способствует принятию обоснованных решений для помощи проекту или бизнесу
- Помогает подобрать нужную модель машинного обучения



Этапы разведочного анализа

1

Описательный
анализ данных

2

Анализ пропусков
и ошибок

3

Визуализация
данных

4

Обнаружение
выбросов

5

Корреляционный
анализ

6

Формирование
выводов



Чем еще дополнить?

- Группируйте данные
- Поймите природу ошибок и пропусков
- Заполните пропуски и проверьте, как это влияет
- Создавайте новые признаки
- Изучите целевую переменную

Исследование = творчество!





ОПИСАТЕЛЬНЫЙ АНАЛИЗ ДАННЫХ



Выборка — это группа объектов или значений, которые были выбраны из общей группы (например, население страны или список продуктов в магазине). Она представляет собой подмножество данных, на основе которого проводится анализ

Какие бывают данные

#1

Количественные
переменные

#3


Текст

#2


Категориальные
переменные

#4

Картинки и т.д.



Центральная предельная теорема



Чем больше выборка, тем ближе ее распределение к **нормальному**

Нормальное распределение (распределение Гаусса) — это распределение, большинство значений которого находятся вокруг среднего

Описательная статистика

Меры центральной тенденции

- Средняя
- Медиана
- Мода

Меры изменчивости

- Дисперсия
- Стандартное отклонение



Меры центральной тенденции

Средняя (среднее арифметическое)

$$m = \frac{2+3+4}{\textcircled{3}} = \frac{9}{3} = 3$$

Количество чисел

Меры центральной тенденции

Медиана — срединное значение набора чисел

- При нечетном количестве:
{5, 8, **21**, 123, 100500} медианой будет **21**
- При четном:
{5, 8, **21**, **23**, 123, 100500,} медиана будет равна $(21 + 23) / 2 = 22$

Меры центральной тенденции

Мода — самое часто встречающееся значение:

- {0, 1, 1, 12, 100, 121} модой будет 1

Меры изменчивости

Дисперсия — мера разброса значений.
Среднее квадратов отклонений

$$\sigma^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

Стандартное отклонение — корень из дисперсии

ВИЗУАЛИЗАЦИЯ ДАННЫХ

Визуализация

Визуализация позволяет оценить графики, построенные на данных

Основные типы графиков:

- Гистограммы
- Диаграммы размаха (ящик с усами)
- Диаграммы рассеяния
- Графики плотности
- Столбчатые диаграммы
- Графики парных признаков



Гистограмма

Позволяет оценить распределение данных






Диаграмма размаха

Позволяет визуализировать распределение данных и их выбросов



- **Квартили (Q)** — значения, которые делят значения на четыре равные части
- **Межквартильный размах (IQR)** — это разница между третьим и первым квартилем $IQR = Q_3 - Q_1$
- **Медиана всей выборки** — второй квартиль
- **Медианы левой и правой половин** — первый и третий квартили


Диаграмма размаха



- **Нижняя граница** — разность первого квартиля и полутора межквартильных расстояний
- **Верхняя граница** — сумма третьего квартиля и полутора межквартильных расстояний
- **Выброс** — значение, выделяющийся из общей выборки


Диаграмма рассеяния

Позволяет оценить связь между переменными




Графики плотности

Позволяют оценить форму распределения данных




Столбчатые диаграммы

Позволяют оценить категориальные данные



Графики парных признаков


Позволяют выявить связи между несколькими переменными



КОРРЕЛЯЦИОННЫЙ АНАЛИЗ

Корреляция

Позволяет посчитать взаимосвязь между признаками




Корреляция

Помогает:

- 01 Найти взаимосвязь между признаками
- 02 Понять силу взаимосвязи между признаками
- 03 Предсказание одного признака по другому
- 04 Отбор признаков



Корреляция



Основные способы pandas.corr():

- Pearson
- Kendall
- Spearman

Корреляция Пирсона

Измеряет линейную связь между двумя наборами данных

Этот коэффициент изменяется в пределах от -1 до +1, причем 0 означает отсутствие корреляции

- -1 или +1 - точная линейная связь
- Положительные корреляции
- Отрицательные корреляции



Примечание: корреляция Пирсона предполагает нормальность и линейность, поэтому обе переменные должны быть нормально распределены

Корреляция Спирмена

Измеряет линейную связь между двумя наборами данных, но уже не с числами, а их рангами, поэтому ранговая корреляция Спирмена

- Этот коэффициент изменяется в пределах от -1 до +1, причем 0 означает отсутствие корреляции
- Не рекомендуется использовать коэффициент Спирмена, если в данных присутствуют выбросы



Примечание: в отличие от корреляции Пирсона, корреляция Спирмена не предполагает, что оба набора данных распределены нормально

Корреляция Кендалла


Измеряет линейную связь между двумя наборами данных, также с их рангами

- Этот коэффициент изменяется в пределах от -1 до $+1$, причем 0 означает отсутствие корреляции



Примечание: часто используется для корреляции данных, в которых есть выбросы

Phik корреляция



Новый тип коэффициента корреляции

- Этот коэффициент изменяется в пределах от 0 до +1, причем 0 означает отсутствие корреляции

Phik не требует предположений о распределении данных





ВОРКШОП

Содержание воркшопа

- ✦ Изучим признаки
- ✦ Почистим ошибки и заполним пропуски
- ✦ Проведем анализ по выданным задачам

ДОМАШНЕЕ ЗАДАНИЕ

Домашнее задание

- 1 Загрузите [датасет](#), изучите признаки
- 2 Проведите исследовательский анализ данных, используя изученные техники
- 3 Сделайте выводы
- 4 Отправьте на проверку ваше исследование в Jupyter notebook (.ipynb)



СПАСИБО ЗА ВНИМАНИЕ!



KirillErokhin23



KirillErokhin



Kasdeja23